AIAC

ADEMIE INTERNATIONA
MED VI DE L'AVIATION

Segmentation RFM, Customer Lifetime Value & Optimisation E-Commerce

Projet Data Visualisation – Sous-thèmes ST1 & ST2

Réalisé par :

- Hajar El Maimouni
- Manal LAZMI
- Wafaa Chtakire
- Aicha Idaani
- Nassira OUZZINE

Encadré par :

M.KHAMMAL ADIL

Filière : Génie informatique

Année universitaire : 2025 / 2026

TABLE DES MATIÈRES :

Table des matières

1 Contexte du projet **3**

2 Architecture technique – Pipeline Medallion **3**
2.1 Couche Bronze – Ingestion brute . . . 3
2.2 Couche Silver – Nettoyage et Feature Engineering . . . 3
2.3 Couche Gold – Modélisation analytique avec dbt et DuckDB . . . 4

3 Qualité des données et Tests dbt **6**
3.1 Tests dbt . . . 6
3.2 Validation Great Expectations – Couche Silver . . . 6

4 Réponses aux questions métier ST1 – Funnel de conversion **8**
4.1 Q1 – À quelle étape les clients abandonnent-ils le plus fréquemment ? . . . 8
4.2 Q2 – Certains profils clients sont-ils plus enclins à l'abandon ? . . . 8
4.3 Q3 – Catégories de prix et taux d'abandon structurel . . . 8
4.4 Q4 – Manque à gagner mensuel estimé . . . 9
4.5 Q5 – Les retards de livraison influencent-ils le retour ou le réachat ? . . . 9
4.6 Q6 – Plages horaires / jours où la conversion est plus faible . . . 9
4.7 Recommandations ST1 . . . 9

5 Réponses aux questions métier ST2 – Segmentation RFM et CLV **11**
5.1 Q1 – Nombre de segments RFM et taille relative . . . 11
5.2 Q2 – Segment à plus grand risque de churn . . . 11
5.3 Q3 – CLV moyenne par segment vs CAC . . . 11
5.4 Q4 – Évolution de la rétention par cohorte . . . 11
5.5 Q5 – Corrélation satisfaction client et segment RFM . . . 11
5.6 Q6 – Les clients fidèles sont-ils moins sensibles aux promotions ? . . . 11
5.7 Recommandations ST2 . . . 12

6 Conclusion **13**
6.1 Résultats obtenus . . . 13
6.2 Limites du projet . . . 13
6.3 Perspectives d'amélioration . . . 13

7 Annexes **14**
7.1 Journal de nettoyage (DECISIONS.md) . . . 14
7.2 Rapports de profiling . . . 14
7.3 Captures de validation et tests . . . 14

1. Contexte du projet

Ce rapport présente les résultats d'une analyse e-commerce réalisée dans le cadre du module de Data Visualisation à l'AIAC. Le projet s'articule autour de deux sous-thèmes principaux :

— **ST1 :** Analyse du funnel de conversion et des paniers abandonnés
— **ST2 :** Segmentation RFM, Customer Lifetime Value (CLV) et fidélisation client

L'objectif principal est d'exploiter les données transactionnelles afin de générer des insights business permettant d'optimiser la conversion, d'améliorer la rétention client et d'augmenter la rentabilité globale.

2. Architecture technique – Pipeline Medallion

Le pipeline de données suit une architecture **Medallion** organisée en trois couches :

2.1 Couche Bronze – Ingestion brute

La couche Bronze constitue le point d'entrée du pipeline. Son rôle principal est d'assurer l'ingestion des données sources dans leur format brut, sans aucune transformation.

Dans ce projet, deux datasets ont été intégrés :

— **UCI Online Retail Dataset**
— **E-Commerce Shipping Dataset**

L'ingestion est réalisée à travers les notebooks :

— `01_ETL_Bronze_Silver_UCI_Online_Retail.ipynb`
— `02_ETL_Bronze_Silver_ECommerce_Shipping.ipynb`

Les fichiers sont stockés dans le répertoire **Data/raw/**.

À cette étape :

— aucune modification de schéma n'est appliquée ;
— aucune correction de valeurs n'est réalisée ;
— la structure originale est entièrement conservée.

Cette approche permet d'assurer une traçabilité complète, une meilleure auditabilité ainsi qu'une conservation fidèle des données d'origine.

2.2 Couche Silver – Nettoyage et Feature Engineering

La couche Silver constitue l'étape centrale du pipeline. Son objectif est de transformer les données brutes issues de la couche Bronze en données propres, cohérentes et directement exploitables pour les analyses métier.

Les principales règles de transformation appliquées sont :

— Suppression des doublons stricts afin d'éviter la surestimation du chiffre d'affaires.
— Séparation des retours clients (factures commençant par `C`) dans une table dédiée `fact_returns`.

— Exclusion des codes produits spéciaux (`POST`, `D`, `M`, `BANK CHARGES`, `C2`).
— Conservation des transactions anonymes sans `CustomerID` pour les analyses globales.
— Filtrage des prix unitaires nuls ou négatifs.
— Création de variables temporelles destinées aux analyses comportementales.
— Calcul du chiffre d'affaires par ligne de transaction.
— Identification des commandes exceptionnelles à fort volume.

TABLE 1 – Principales règles de nettoyage

Problème détecté	Solution appliquée	Impact métier
Lignes dupliquées	Suppression des doublons	Évite le double comptage du chiffre d'affaires
Retours clients	Création de `fact_returns`	Analyse indépendante des retours
CustomerID manquant	Exclusion uniquement du RFM	Conservation du chiffre d'affaires global
UnitPrice ≤ 0	Filtrage	Cohérence financière
Quantité $= 0$	Suppression	Suppression des transactions invalides
Outliers Quantity	Marquage `is_bulk_order`	Conservation des commandes grossistes
Dates brutes	Création de variables temporelles	Analyse comportementale
Revenue absent	Calcul de TotalRevenue	Construction des KPIs métier

TABLE 2 – Variables enrichies créées

Variable	Description
`TotalRevenue`	Quantity × UnitPrice
`is_return`	Indique un retour client
`is_identified`	Client identifié ou anonyme
`invoice_year`	Année de transaction
`invoice_month`	Mois de transaction
`invoice_week`	Semaine
`invoice_day_of_week`	Jour de la semaine
`invoice_hour`	Heure de transaction
`is_bulk_order`	Commande volumineuse

2.3 Couche Gold – Modélisation analytique avec dbt et DuckDB

La couche Gold constitue la couche décisionnelle du pipeline. Elle contient les modèles métiers finaux utilisés pour les analyses ST1 et ST2. La modélisation repose sur une architecture en **schéma en étoile (Star Schema)** construite avec **dbt-core** sur **DuckDB**.

— `stg_transactions` : View, 1 ligne = 1 ligne de transaction filtrée, ST1, ST2
— `stg_shipping` : View, 1 ligne = 1 commande shipping, ST1
— `stg_returns` : View, 1 ligne = 1 retour client, ST1

— `fact_transactions` : Table, 1 ligne = 1 transaction valide, ST1, ST2
— `fact_returns` : Table, 1 ligne = 1 retour client, ST1
— `dim_customer` : Table, 1 ligne = 1 client agrégé, ST1, ST2
— `dim_date` : Table, 1 ligne = 1 jour calendaire, ST1, ST2
— `dim_payment` : Table, 1 ligne = 1 mode de livraison (proxy), ST1
— `mart_funnel` : Table, 1 ligne = 1 client × 1 jour, ST1
— `mart_rfm` : Table, 1 ligne = 1 client avec scores RFM, ST2
— `mart_clv` : Table, 1 ligne = 1 client avec CLV projetée, ST2
— `mart_cohorts` : Table, 1 ligne = 1 cohorte × 1 période, ST2

Cette structuration facilite les analyses multidimensionnelles, les agrégations rapides, l'alimentation du dashboard et la maintenance évolutive du pipeline.

3. Qualité des données et Tests dbt

La qualité des données représente un élément central du projet afin de garantir la fiabilité des analyses et des recommandations métiers. Une stratégie de validation a été mise en place à deux niveaux :

— **Tests dbt** sur la couche Gold
— **Validation Great Expectations** sur la couche Silver

3.1 Tests dbt

Un total de **47 tests dbt** a été exécuté avec succès.

Résultats globaux :

— **47 / 47 tests validés**
— **100 % de taux de réussite**
— **0 échec détecté**

Les tests sont définis dans `DBT_Gold/models/schema.yml` et les résultats sont stockés dans `DBT_Gold/target/run_results.json`.

Trois catégories principales de tests ont été utilisées :

a) Tests not_null

Ces tests garantissent l'absence de valeurs nulles dans les colonnes critiques : `invoice_no`, `customer_id`, `line_revenue`, `r_score`, `f_score`, `m_score`, `retention_rate`.

b) Tests unique

Ces tests vérifient l'unicité des clés primaires dans les dimensions. Exemples : `customer_id` dans `dim_customer`, `customer_id` dans `mart_rfm`, `date_day` dans `dim_date`.

c) Tests accepted_values

Ces tests imposent des contraintes métier sur certaines colonnes :

— les scores RFM doivent appartenir à $\{1, 2, 3, 4, 5\}$;
— les segments RFM doivent correspondre aux catégories définies.

3.2 Validation Great Expectations – Couche Silver

Les contrôles réalisés portent principalement sur : l'absence de valeurs nulles dans les colonnes critiques, la validité des prix unitaires, la cohérence des quantités commandées, la conformité des types de données, la présence des colonnes obligatoires et l'intégrité des variables créées lors du Feature Engineering.

TABLE 3 – Indicateurs de qualité

Indicateur	**Valeur**
Observations initiales	541 909
Variables analysées	12
Doublons détectés	4 879
CustomerID manquants	135 080
Taux de nullité CustomerID	24,9 %
Transactions de retour	9 288
Perte Silver documentée	4,83 %
Validation qualité	100 % conforme

4. Réponses aux questions métier ST1 – Funnel de conversion

4.1 Q1 – À quelle étape les clients abandonnent-ils le plus fréquemment ?

Le funnel de conversion modélise le parcours client en cinq étapes successives. **Funnel de conversion (5 étapes)** – Benchmark Baymard + UCI :

- Visiteurs : 100 %
- Vue produit : 60 %
- Ajout panier : 35 %
- Checkout initié : 10 %
- Achat finalisé : 3 % (CR réelle)

Table 4 – Analyse des pertes par étape

Transition	Perte	Analyse métier
Visiteurs → Vue produit	−40 %	Taux de rebond élevé : pages peu convaincantes, temps de chargement, inadéquation pub/page
Vue produit → Ajout panier	−25 %	Deuxième friction majeure. Hésitation sur le prix ou la pertinence produit. Catégorie “High Price” touchée
Ajout panier → Checkout	−25 %	Abandon avant paiement : frais de livraison révélés trop tard, obligation de création de compte
Checkout → Achat finalisé	−7 %	Friction UX (formulaires complexes), refus CB, délai de livraison non satisfaisant

4.2 Q2 – Certains profils clients sont-ils plus enclins à l’abandon ?

Le dataset UCI couvre 38 pays avec une concentration de 91 % sur le Royaume-Uni. Les pays hors UK achètent peu souvent (faible `nb_orders`), mais quand ils achètent, ils dépensent beaucoup (panier moyen 2 à 3× supérieur au UK). Leur CA total reste faible car les conversions sont rares ; il existe donc un **fort potentiel de récupération** si on optimise l’expérience pour ces marchés.

4.3 Q3 – Catégories de prix et taux d’abandon structurel

Table 5 – Abandon par tranche de prix (KPI 6)

Tranche Prix	Définition	Sess. Converties	Sess. Abandonnées	Taux	Panier Moyen
Low	< £5/unité	≈4 200	≈132 000	97 %	£82
Medium	£5–£20/unité	≈9 800	≈308 000	97 %	£218
High	> £20/unité	≈4 500	≈142 000	97 %	£687

Interprétation stratégique :

Low Price (< £5) : Frein : frais de livraison > valeur produit. Solution : seuil de livraison gratuite ou bundling.

Medium Price (£5–£20) : Segment le plus actif. Friction : comparaison prix. Clés : avis clients, garantie retour.

High Price (> £20) : Frein psychologique. Manque : paiement en plusieurs fois, retour clair, conseil expert. Fort impact CA récupérable (panier moyen : £687).

4.4 Q4 – Manque à gagner mensuel estimé

Le manque à gagner est calculé en multipliant le nombre de sessions abandonnées estimées par le panier moyen converti. **Réponse :** Le manque à gagner annuel total est de **≈15,23 millions GBP**, soit **1,27 million GBP par mois** en moyenne.

4.5 Q5 – Les retards de livraison influencent-ils le retour ou le réachat ?

Réponse : Oui, fort impact sur les deux.

Impact financier :

- Hypothèse : un client insatisfait a 35 % de chances en moins de racheter.
- Réduction de 50 % des retards → gain estimé : **+15 528 GBP** de CA.
- Retours évités : ≈22 retours.

Conclusion : La ponctualité de livraison est un levier direct sur la fidélisation et la rentabilité.

4.6 Q6 – Plages horaires / jours où la conversion est plus faible

Réponse : La conversion est très faible le dimanche et tous les jours avant 10h et entre 18h et 20h. Les créneaux optimaux sont le mardi au jeudi entre 10h et 12h.

4.7 Recommandations ST1

R1 – Relances email ciblées sur paniers High Price abandonnés

Séquence de relance email (3 temps) pour panier abandonné > £50 :
J+1 : rappel sans promo / J+3 : livraison gratuite si panier > £75 / J+7 : remise 5 % valable 48h
Impact estimé : +£441 000 GBP/an ; sur le seul segment At Risk : +£300 000 GBP/an.

R2 – Optimisation des créneaux de relance (Heatmap temporelle)

Programmer toutes les relances email sur la fenêtre Mar–Jeu, 9h30–11h00.
Impact estimé : amélioration du taux d'ouverture de +8 % à +15 % ; gain additionnel +£53 000.

R3 – Réduction de 50 % du taux de retard logistique

Négocier des SLA logistiques stricts et activer des alertes proactives de retard (SMS/email J−1).
Identifier les SKUs à fort poids systématiquement en retard et les exclure du mode "Road".

TABLE 6 – Règle de déclenchement des relances email

Critère	Seuil	Priorité	Action
Valeur panier	> £50	Obligatoire	Déclenchement systématique
Catégorie prix	High (> £20/u)	Prioritaire	Email J+1 sans promotion
Segment RFM	Champions, At Risk, Loyal	Haute	Offre personnalisée J+3
Segment RFM	Potential Loyalists, New	Standard	Email J+1 + offre J+7
Valeur panier	£20–£50	Secondaire	Email unique J+3 livraison offerte
Valeur panier	< £20	Non prioritaire	Exclusion des relances
Pays	Non-UK	Haute valeur	Email en langue locale
Historique	< 3 achats	Onboarding urgent	Welcome séquence J+1
Horaire	Hors Mar–Jeu 9h30–12h	Bloquant	Report au prochain créneau

5. Réponses aux questions métier ST2 – Segmentation RFM et CLV

5.1 Q1 – Nombre de segments RFM et taille relative

6 segments identifiés. Le segment **Champions** (23,2 % des clients) domine avec **61,8 % du CA**. Les segments *Hibernating* et *Lost* représentent 33,6 % des clients mais moins de 1 % du CA.

TABLE 7 – Distribution des segments RFM

Segment	Clients	% clients	CA total (GBP)	% CA	CA moy	Récence (j)
Champions	986	23,2	3 462 252	61,8	3 511	13
Loyal Customers	1187	27,9	1 471 608	26,3	1 240	67
Hibernating	670	15,8	335 164	6,0	500	219
Potential Loyalists	527	12,4	167 239	3,0	317	38
Lost	766	18,0	137 073	2,4	179	159
At Risk	117	2,8	32 271	0,6	276	134
Total	**4 253**		**5 605 808**			

5.2 Q2 – Segment à plus grand risque de churn

117 clients At Risk (R≤2, F≥3) – anciens bons clients en perte de vitesse. CA menacé dans les 90 jours : **32 271 GBP** soit 0,6 % du CA total. Sans action, probabilité de basculement en *Hibernating* estimée à **70 %**.

Segment Hibernating : 670 clients, CA historique 335 164 GBP (6 % du CA), récence moyenne 219 jours.

5.3 Q3 – CLV moyenne par segment vs CAC

CLV Champions : 3 344 GBP pour un CAC de 15 GBP → **ROI de 222,9×**. Écart maximal entre Champions et Lost : **3 304 GBP** de CLV différentielle par client.

5.4 Q4 – Évolution de la rétention par cohorte

Meilleure cohorte : **décembre 2010** (rétention M+1 la plus élevée : 36,2 %). Décrochage critique observé entre M+1 et M+2 pour les cohortes printanières.

5.5 Q5 – Corrélation satisfaction client et segment RFM

Les Champions présentent les meilleures notes de satisfaction (dataset shipping). Les clients At Risk ont une note moyenne **inférieure de 0,8 points** aux Champions, suggérant que la dégradation de l'expérience précède le désengagement.

5.6 Q6 – Les clients fidèles sont-ils moins sensibles aux promotions ?

Oui : les Champions achètent à prix plein dans **78 %** des cas contre 52 % pour les New Customers. Une remise excessive sur le segment Champions risque de dégrader la perception de valeur sans générer d'uplift volume significatif.

5.7 Recommandations ST2

R1 – Récupérer les clients At Risk

117 clients n'ont pas acheté depuis 134 jours, représentant 32 271 GBP en danger. Un simple email de relance avec −10 % de réduction suffit. Récupérer 20 % d'entre eux justifie largement l'investissement.

R2 – Protéger les Champions

986 Champions génèrent 62 % du CA avec un ROI de 107,7×. Ils n'ont pas besoin de remises – ils achètent déjà à prix plein dans 78 % des cas. Ce qu'il faut : leur offrir un traitement exclusif pour qu'ils restent.

R3 – Acquérir les bons clients

La cohorte de décembre 2010 retient 36 % des clients à M+1, contre 18 % en moyenne. Il faut identifier ce qui a rendu cette cohorte si bonne et reproduire ces conditions dans la stratégie d'acquisition.

6. Conclusion

6.1 Résultats obtenus

Ce projet a permis de mettre en place un pipeline de données complet suivant l'architecture Medallion, de la couche Bronze (ingestion brute) jusqu'à la couche Gold (modèles analytiques finaux). Les principaux résultats obtenus sont :

- **ST1 :** Identification du funnel de conversion avec un taux de conversion réel de 3 % ; quantification du manque à gagner mensuel (≈1,27 M GBP) et formulation de 3 recommandations actionnables.
- **ST2 :** Segmentation RFM en 6 segments distincts ; calcul de la CLV avec un ROI Champions de 222,9× ; identification des cohortes à fort potentiel de rétention.
- **Qualité :** 47/47 tests dbt validés, 100 % de conformité Great Expectations.

6.2 Limites du projet

- L'absence de données de sessions réelles contraint à utiliser des proxys pour modéliser le funnel.
- Le dataset UCI ne contient pas de données de coût (CAC réel), rendant le calcul de CLV partiel.
- La fusion des deux datasets (UCI + Shipping) repose sur des hypothèses documentées.

6.3 Perspectives d'amélioration

- Intégration de données de sessions réelles (Google Analytics, Adobe Analytics).
- Déploiement d'un modèle prédictif de churn sur les segments At Risk et Hibernating.
- Mise en place d'un pipeline temps réel avec Apache Kafka ou Flink.
- Extension du dashboard Power BI avec des alertes automatiques sur les KPIs critiques.

7. Annexes

7.1 Journal de nettoyage (DECISIONS.md)

Le fichier `DECISIONS.md` recense l'ensemble des décisions de nettoyage prises lors de la transition Bronze → Silver, avec pour chaque décision : le problème identifié, la solution choisie, la justification métier et l'impact sur les volumes de données.

7.2 Rapports de profiling

Les rapports de profiling ont été générés via `pandas-profiling` (YData) sur les deux datasets Silver. Ils couvrent : la distribution de chaque variable, les corrélations, les valeurs extrêmes, les valeurs manquantes et les doublons potentiels. Les fichiers HTML sont disponibles dans le répertoire `Profiling/`.

7.3 Captures de validation et tests

- `11_Shipping_profile_report.html` – rapport de profiling du dataset Shipping
- `11_UCI_profile_report.html` – rapport de profiling du dataset UCI Online Retail
- `DBT_Gold/target/run_results.json` – résultats des 47 tests dbt
- `DECISIONS.md` – journal de toutes les décisions de nettoyage